

Laporan Praktikum Minggu Ke-4 Kontrol Cerdas

Minggu ke-4

Nama : Fahrul Ikhza Fadilla
NIM : 224308055
Kelas : TKA 7C
Akun Github (Tautan) : <https://github.com/FahrulIkhza>

1. Judul Percobaan

Reinforcement Learning for Autonomous Control

2. Tujuan Percobaan

Tujuan dari praktikum “Color detection with Machine Learning”, mahasiswa diharapkan mampu:

1. Memahami konsep dasar Reinforcement Learning (RL) dalam sistem kendali.
2. Mengimplementasikan agen RL menggunakan algoritma Deep Q-Network (DQN).
3. Menggunakan OpenAI Gym sebagai simulasi lingkungan untuk pelatihan RL.
4. Melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.
5. Menggunakan GitHub untuk version control dan dokumentasi praktikum.

3. Landasan Teori

a. Reinforcement Learning (RL)

Reinforcement Learning atau RL adalah salah satu metode pembelajaran mesin di mana sebuah agen belajar dengan cara mencoba berbagai tindakan di sebuah lingkungan. Agen akan mendapatkan reward (hadiah) bila tindakannya benar dan penalty (hukuman) bila tindakannya salah. Dari proses mencoba ini, agen dapat menemukan strategi terbaik untuk mencapai tujuan. RL banyak digunakan pada sistem kendali karena tidak membutuhkan model matematis yang pasti, cukup dengan pengalaman langsung dari interaksi dengan lingkungan.

b. Deep Q-Network (DQN)

Deep Q-Network (DQN) merupakan pengembangan dari metode Q-Learning. Pada Q-Learning, agen menyimpan nilai Q pada sebuah tabel. Namun, jika kondisi yang ada terlalu banyak, tabel tersebut akan menjadi sangat besar dan sulit digunakan. DQN menyelesaikan masalah ini dengan menggunakan jaringan saraf tiruan (neural network) untuk memperkirakan nilai Q. Dengan cara ini, agen bisa belajar di lingkungan yang kompleks dan memiliki banyak kemungkinan kondisi. Tujuan utama DQN adalah membuat agen bisa memilih urutan tindakan yang menghasilkan reward paling besar dalam jangka panjang.

c. OpenAI Gym

OpenAI Gym adalah sebuah pustaka atau platform yang menyediakan berbagai simulasi lingkungan untuk keperluan pembelajaran Reinforcement Learning. Gym membantu peneliti maupun mahasiswa untuk menguji algoritma RL tanpa harus membuat simulasi dari nol. Dalam Gym sudah tersedia banyak sekali environment, mulai dari yang sederhana seperti menjaga keseimbangan tiang (CartPole) hingga yang lebih kompleks seperti mendaratkan roket (LunarLander). Dengan Gym, proses eksperimen dan pelatihan agen menjadi lebih mudah dan standar.

d. Environment CartPole

CartPole adalah salah satu environment paling sederhana di OpenAI Gym. Tugas agen adalah menjaga agar sebuah tiang tetap berdiri seimbang di atas gerobak yang dapat bergerak ke kiri atau ke kanan. Agen akan mendapat reward selama tiang masih seimbang, dan episode akan berakhir jika tiang jatuh atau waktu habis. Meskipun terlihat sederhana, CartPole sering digunakan sebagai langkah awal untuk memahami konsep dasar Reinforcement Learning, karena agen harus belajar memilih aksi yang tepat secara cepat agar tiang tidak jatuh.

e. Environment MountainCar

MountainCar adalah environment di mana agen mengendalikan sebuah mobil kecil yang berada di lembah di antara dua bukit. Tantangan utamanya adalah mobil tidak memiliki tenaga cukup untuk langsung naik ke puncak. Oleh karena itu, agen harus belajar memanfaatkan momentum dengan cara mengayun mobil ke kiri dan ke kanan hingga akhirnya bisa mencapai puncak bukit. Reward dalam lingkungan ini jarang diberikan, hanya saat mobil berhasil mencapai tujuan. Hal ini membuat MountainCar lebih sulit dibanding CartPole, karena agen perlu strategi yang lebih cerdas untuk menemukan solusi.

4. Analisis dan Diskusi

Analisis Hasil:

a. Bagaimana performa agen dalam mengontrol environment CartPole?

Agan Reinforcement Learning (RL) pada awal pelatihan sering gagal menjaga keseimbangan tiang di environment CartPole. Hal ini wajar karena agen masih mencoba berbagai tindakan secara acak tanpa strategi yang jelas. Namun, seiring berjalannya waktu dan semakin banyak pengalaman yang diperoleh, agen mulai menunjukkan perkembangan. Tiang yang awalnya cepat jatuh dapat bertahan lebih lama dalam kondisi seimbang. Hal ini membuktikan bahwa agen mampu belajar dari kesalahan sebelumnya dan mengembangkan strategi yang lebih baik.

b. Bagaimana perubahan parameter (misal: gamma, epsilon, learning rate) mempengaruhi kinerja agen?

Parameter yang digunakan dalam pelatihan sangat memengaruhi keberhasilan agen. Nilai gamma (*discount factor*) yang tinggi membuat agen memperhatikan reward jangka panjang, sehingga tindakannya lebih strategis. Jika nilai gamma terlalu rendah, agen cenderung hanya fokus pada reward sesaat. Parameter epsilon (*exploration rate*) juga penting karena saat nilainya besar, agen lebih banyak bereksperimen dengan aksi acak untuk menemukan strategi baru. Nilai epsilon kemudian diturunkan secara bertahap agar agen lebih sering menggunakan aksi yang sudah terbukti efektif. Selain itu, *learning rate* berfungsi menentukan seberapa cepat agen memperbarui nilai prediksinya. Nilai yang terlalu besar bisa membuat pembelajaran tidak stabil, sementara nilai yang terlalu kecil justru memperlambat proses belajar.

c. Apa tantangan yang muncul selama pelatihan agen RL?

Selama proses pelatihan, agen sering mengalami fluktuasi reward yang menyebabkan hasil pembelajaran tidak stabil. Selain itu, agen harus bisa menyeimbangkan antara eksplorasi untuk mencoba strategi baru dan eksploitasi untuk memanfaatkan strategi yang sudah ada. Tantangan lain adalah lamanya waktu pelatihan dan besarnya kebutuhan sumber daya komputasi, terutama ketika menggunakan algoritma DQN yang kompleks.

Diskusi :

a. Perbedaan RL dengan Supervised Learning

Reinforcement Learning memiliki perbedaan mendasar dengan supervised learning. Pada supervised learning, model dilatih dengan data yang sudah memiliki label benar, sehingga pembelajaran didasarkan pada contoh yang jelas. Sementara itu, RL tidak menggunakan label, melainkan belajar langsung dari interaksi dengan lingkungan. Agen berusaha

menemukan strategi terbaik melalui proses coba-coba, dengan tujuan memaksimalkan reward kumulatif. Perbedaan lainnya adalah supervised learning berfokus pada akurasi prediksi, sedangkan RL menekankan pada efektivitas strategi jangka panjang.

b. Optimasi Strategi Eksplorasi dan Eksploitasi

Dalam RL, eksplorasi dilakukan agar agen dapat mencoba berbagai kemungkinan aksi untuk menemukan strategi baru, sementara eksploitasi digunakan ketika agen memilih strategi yang sudah terbukti efektif. Untuk menyeimbangkan keduanya, digunakan teknik epsilon decay, yaitu pengurangan nilai epsilon secara bertahap. Dengan metode ini, agen bisa banyak bereksplorasi di awal pelatihan, lalu secara perlahan lebih sering mengeksploitasi strategi terbaik yang sudah dipelajari.

c. Potensi Aplikasi RL dalam Sistem Kendali Nyata

Reinforcement Learning memiliki potensi besar untuk diterapkan pada sistem kendali di dunia nyata. Dalam bidang robotika, RL dapat digunakan untuk mengatur pergerakan robot baik dalam navigasi maupun manipulasi objek. Sedangkan pada kendaraan otonom, RL berperan dalam pengambilan keputusan agar mobil dapat bergerak secara mandiri dengan aman dan efisien. Potensi ini menunjukkan bahwa RL tidak hanya berguna dalam simulasi, tetapi juga relevan untuk mendukung perkembangan teknologi modern.

5. Assignment

Pada praktikum minggu keempat ini, mahasiswa mendapat tugas untuk membuat sebuah program yang menerapkan algoritma **Deep Q-Network (DQN)** pada environment **MountainCar-v0** menggunakan pustaka Gymnasium. Tujuan dari program ini adalah melatih agen agar mampu mencapai puncak bukit dengan belajar dari pengalaman yang diperoleh selama proses interaksi dengan lingkungan. Program ini menerapkan konsep **experience replay**, yaitu sebuah mekanisme di mana pengalaman agen selama pelatihan disimpan dalam **memory buffer**. Pengalaman tersebut kemudian dipilih secara acak untuk digunakan kembali dalam proses pembelajaran. Cara ini membuat proses pelatihan lebih stabil karena agen tidak hanya bergantung pada pengalaman terbaru, melainkan juga dapat belajar dari pengalaman yang lebih lama.





Di dalam program, dibuat kelas **DQNAgent** yang berisi fungsi-fungsi penting untuk mendukung proses pembelajaran. Fungsi `act()` digunakan untuk menentukan aksi agen dengan strategi **epsilon-greedy**, sehingga agen tetap memiliki kesempatan untuk mengeksplorasi lingkungan pada awal pelatihan,

lalu beralih pada eksploitasi strategi yang sudah terbukti efektif. Fungsi ``remember()`` berperan untuk menyimpan setiap pengalaman yang didapatkan, sedangkan fungsi ``replay()`` digunakan untuk mengambil pengalaman dari **memory buffer** dan melatih ulang model agar perkiraan nilai Q semakin akurat. Proses pelatihan dimulai dengan mengatur ulang kondisi lingkungan, kemudian agen secara berulang melakukan aksi, menerima reward, menyimpan pengalaman, serta memperbarui model berdasarkan data yang terkumpul. Apabila jumlah pengalaman dalam **memory buffer** sudah mencukupi, agen mulai menjalankan pelatihan untuk meningkatkan kualitas keputusannya.

Selain itu, program ini juga terhubung dengan **Pygame** yang memungkinkan penghentian otomatis apabila jendela permainan ditutup oleh pengguna. Meskipun demikian, penggunaan mode tampilan (**human render**) membuat proses pelatihan berjalan lebih lambat. Oleh karena itu, tampilan visual sebaiknya dinonaktifkan selama tahap pelatihan dan hanya diaktifkan ketika evaluasi agar proses belajar lebih efisien. Dalam implementasinya, beberapa parameter seperti gamma, epsilon decay, maupun arsitektur jaringan saraf dapat disesuaikan untuk melihat pengaruhnya terhadap kinerja agen. Untuk hasil yang lebih optimal, metode **prioritized experience replay** juga bisa ditambahkan agar agen lebih sering belajar dari pengalaman yang paling penting. Dengan cara ini, diharapkan agen dapat berlatih lebih cepat, lebih stabil, dan lebih efisien dalam menyelesaikan tantangan **MountainCar-v0**.

6. Data dan Output Hasil Pengamatan

No	Variabel	Hasil Pengamatan	
		CartPole	MountainCar
1.	Waktu Pelatihan	Lebih cepat mencapai performa optimal dalam beberapa ratus episode	Membutuhkan lebih banyak waktu untuk mencapai keberhasilan yang stabil
2.	Kondisi Awal untuk Scorenya	Skor bervariasi tergantung seberapa lama tiang tetap seimbang.	Skor awal mencapai 199 karena maksimal langkah dalam satu episode adalah 200.
3.	Kondisi Akhir	Episode berakhir jika tiang jatuh atau batas langkah maksimum tercapai	Episode berakhir jika mobil mencapai puncak bukit (bendera)
4.	Prinsip Kerja	Sistem ini mengikuti hukum fisika, di mana jika tongkat	Sistem ini menampilkan sebuah mobil kecil berada di

		mulai miring, gerobak harus segera bergerak ke arah kemiringan untuk menyeimbangkannya. Jadi, tongkat harus tetap seimbang di atas gerobak yang bergerak ke kiri atau kanan.	lembah di antara dua bukit dan harus mencapai puncak salah satu bukit. Mobil tidak memiliki tenaga yang cukup untuk langsung naik, sehingga harus mengandalkan momentum dengan cara mengayun bolak balik agar dapat mencapai ketinggian yang cukup.
5.	Hasil		
6.	Score	<pre> Target Network updated! Episode: 92/100, Score: 13, Epsilon: 0.41 Episode: 93/100, Score: 15, Epsilon: 0.40 Episode: 94/100, Score: 25, Epsilon: 0.40 Episode: 95/100, Score: 14, Epsilon: 0.40 Episode: 96/100, Score: 16, Epsilon: 0.39 Episode: 97/100, Score: 15, Epsilon: 0.39 Episode: 98/100, Score: 69, Epsilon: 0.38 Episode: 99/100, Score: 29, Epsilon: 0.38 Episode: 100/100, Score: 18, Epsilon: 0.38 </pre>	<pre> Episode: 1/50, Score: 199, Epsilon: 1.00 Target Network updated! Episode: 2/50, Score: 199, Epsilon: 0.99 Episode: 3/50, Score: 199, Epsilon: 0.99 Episode: 4/50, Score: 199, Epsilon: 0.99 Episode: 5/50, Score: 199, Epsilon: 0.98 Episode: 6/50, Score: 199, Epsilon: 0.98 Episode: 7/50, Score: 199, Epsilon: 0.97 Episode: 8/50, Score: 199, Epsilon: 0.97 Episode: 9/50, Score: 199, Epsilon: 0.96 Episode: 10/50, Score: 199, Epsilon: 0.96 Episode: 11/50, Score: 199, Epsilon: 0.95 Target Network updated! Episode: 12/50, Score: 199, Epsilon: 0.95 </pre>
7.	Grafik		

7. Kesimpulan

Dari percobaan yang telah dilakukan dapat disimpulkan bahwa:

1. Metode **prioritized experience replay** dapat membuat agen belajar lebih cepat karena pengalaman yang penting lebih sering digunakan dalam proses pelatihan.

2. Mode tampilan visual (*human render*) menyebabkan proses pelatihan menjadi lambat. Oleh karena itu, tampilan sebaiknya dimatikan selama pelatihan dan hanya digunakan saat evaluasi hasil.
3. Pada lingkungan dengan reward yang jarang seperti *MountainCar*, agen membutuhkan waktu eksplorasi yang lebih panjang serta *replay buffer* yang lebih besar agar dapat menemukan strategi yang efektif.
4. Penggunaan **target network** terbukti membantu menjaga kestabilan pembelajaran dengan mencegah perubahan nilai Q yang terlalu drastis.
5. Melalui algoritma DQN, agen dapat memahami bahwa sekadar bergerak maju tidak cukup untuk mencapai tujuan. Agen belajar bahwa perlu mundur terlebih dahulu untuk mengumpulkan momentum sebelum berhasil mencapai puncak.

8. Saran

Untuk meningkatkan efektivitas pembelajaran agen pada environment *MountainCar-v0*, ada beberapa hal yang bisa dioptimalkan. Pertama, pengaturan parameter seperti gamma, epsilon decay, dan ukuran *memory buffer* perlu disesuaikan agar agen dapat belajar lebih efisien dan menemukan strategi terbaik dengan lebih cepat. Selain itu, metode **prioritized experience replay** bisa digunakan agar agen lebih sering berlatih dari pengalaman yang penting, sehingga proses pelatihan menjadi lebih efektif.

Dari sisi efisiensi, karena *MountainCar-v0* membutuhkan banyak episode untuk mencapai hasil yang stabil, sebaiknya mode tampilan visual (*human render*) dimatikan selama pelatihan agar tidak memperlambat proses. Tampilan tersebut dapat diaktifkan kembali hanya saat evaluasi untuk melihat performa akhir agen. Dengan langkah-langkah perbaikan ini, diharapkan agen dapat belajar lebih cepat, lebih stabil, dan lebih efisien dalam menyelesaikan tantangan *MountainCar-v0*.

10. Daftar Pustaka

- Abadi, Arulkumaran, K., Deisenroth, M. P., Brundage, M. & Bharath, A. A., 2017. Deep reinforcement learning: A brief survey. *IEEE Signal Processing Magazine*, 34(6), pp. 26-38. 2.
- Barto, A. G., Sutton, R. S. & Anderson, C. W., 1983. Neuronlike adaptive elements that can solve difficult learning control problems. *IEEE Transactions on Systems, Man, and Cybernetics*, SMC 13(5), pp. 834-846.
- Andreanus, J., & Kurniawan, A. (2018). Sejarah, Teori Dasar dan Penerapan Reinforcement Learning: Sebuah Tinjauan Pustaka. *Jurnal Telematika*, 12(2), 113-118. <https://doi.org/10.61769/telematika.v12i2.193>
- Gou, S. Z., & Liu, Y. (2019). DQN with model-based exploration: Efficient learning on environments with sparse rewards (No. arXiv:1903.09295). arXiv. <https://doi.org/10.48550/arXiv.1903.09295>